

单目视觉端到端自动驾驶跨场景鲁棒性的网络侧优化报告

执行摘要

这份报告只讨论**网络本身的优化**，不讨论数据增强、风格迁移、合成数据扩充、主动清洗样本等“数据侧优化”手段。结合近五年单目或相机主导端到端自动驾驶研究，一个相对稳定的结论是：跨场景鲁棒性通常不是靠单纯“加大 backbone”获得，而是靠**几何感知的表征、短中期时序记忆、多任务辅助先验、带不确定性的规划头，以及更稳健的训练归一化与部署链路**共同获得。以单目/相机主导方法为例，TCP 证明了“单相机 + 轨迹/控制双分支”就可以在 CARLA 闭环场景取得很强表现；VADv2 把规划建模为概率分布后，在 camera-only 闭环评测上继续提升；RoCA 进一步把跨城市跨域泛化问题显式化；SUPER-AD 则显示把语义不确定性注入规划头对困难场景尤其有价值；CarLLaVA、DriveGPT4、EMMA 等工作又说明，可解释输出与多任务统一建模并不只是“锦上添花”，而是在错误定位、行为审计与开放场景泛化上开始变成结构性能力。¹


如果你的目标是“尽快把一个现有单目端到端驾驶网络做得更抗场景变化”，我最建议的网络侧路线不是一步到位上超大模型，而是先把体系做成五件事：第一，用**多尺度主干 + 几何条件输入**替代只看 RGB 的平面特征；第二，在 3-8 帧短时序上加入**GRU 或 CfC**，如果资源允许再演进到 streaming transformer；第三，给主干增加**深度/语义/车道或道路结构辅助头**，但通过动态权重避免主任务被“辅助任务绑架”；第四，把规划头从单一 deterministic waypoint regression 升级到**轨迹分布或风险敏感规划头**；第五，把 BN 改成 **GN/LN**、配合蒸馏与 QAT/INT8 完成部署闭环。按文献与开源实现的综合证据看，这组改动的性价比明显高于单独堆 SE/CBAM 或单独换更大的视觉 backbone。²

需要提前说明的是，当前公开研究在“统一单目、统一数据、统一闭环协议、统一计算预算”下的 apples-to-apples 对比仍然不足。因此，下面的优先级与收益判断是以**原始论文、官方代码库、主流 benchmark 页面**为依据做出的工程化综合判断，而不是宣称所有方法已经在同一赛道被严格比较。³

范围与推荐基线

在你当前的约束下，一个适合做“网络侧鲁棒性优化”的推荐基线，应当从“单帧 RGB 直接回归转角/油门/刹车”的极简结构，升级到“**单目图像序列 → 多尺度几何表征 → 短时序记忆 → 轨迹/控制联合输出 → 不确定性或可解释辅助输出**”的结构。这样做的原因是，跨光照、天气、道路类型、相机参数、城市/乡村变化，本质上都会先体现在**尺度变化、几何投影变化、可见性变化和时序连续性破坏**上；如果网络内部没有显式处理这些因素，它就容易把场景相关的外观模式误当成驾驶规律。PersFormer 通过相机参数感知的 perspective transform 改善了 3D lane 几何建模；BEVFormer 通过空间-时间 transformer 说明了 camera-only 表征在低可见条件下可以靠时序信息提升；MGNet 则说明深度与 panoptic 这样的几何/语义辅助任务能在单目下形成更强的场景理解。⁴

下面这个结构图，更接近我建议你优先演进的“中等算力、面向跨场景鲁棒”的单目端到端网络，而不是纯研究型的大而全系统：



如果你目前没有 BEV 表征，也不必一开始就上完整 BEV。对单目系统来说，**显式 BEV 不是必须项，但几何条件注入几乎是必须项**。因为不同焦距、裁剪方式、安装高度和画面纵横比会导致同一视觉模式对应完全不同的驾驶尺度含义，这正是跨相机参数迁移容易失效的根本原因之一。PersFormer 的相机参数参考型变换、STMono3D 对“camera-parameter-induced depth shift”的分析，都指向了同一件事：哪怕不做完整 3D 重建，也应当把相机几何条件作为网络输入的一部分，而不是把它藏在预处理里。 ⁵

核心网络改进方法详述

下面先给出一张“方法详表”。它覆盖了你最关心的网络侧改动项：多任务学习、GRU/CfC/Transformer、注意力模块、多尺度、光流/运动流、深度/语义/实例辅助、可解释性、不确定性、归一化替代、蒸馏压缩。表格后的“决策矩阵”再专门回答复杂度、训练成本和跨场景收益。

具体改进	原理	主要优点	主要缺点/风险	实现要点	参考实现/证据	适用场景	预期收益
多任务辅助头	共用主干，同时输出轨迹、语义、车道、道路图、目标等，让主干学到更稳定的结构先验	对光照/天气变化更稳，错误更容易定位；EMMA、PersFormer、MGNet 都显示协同任务可提升主任务表征	任务冲突明显，若权重设置差会拖累控制头	建议“共享主干 + 轻量 task head + 动态权重”；优先加语义/车道/深度，不要一口气加太多头	EMMA 多任务协同提升规划、检测、road graph；PersFormer 2D/3D lane 辅助；MGNet 深度+panoptic 官方实现 ⁶	城市道路、车道规则强、长尾标志多	高
动态任务加权	用不确定性权重、GradNorm、CAGrad 等自动平衡多任务梯度	解决“辅助任务压主任务”问题，减少手调权重成本	引入训练复杂度；不同方法对稳定性敏感	初期优先不确定性权重；任务明显冲突时再上 CAGrad/GradNorm	Kendall 不确定性加权、GradNorm、CAGrad 均为成熟方案 ⁷	已有多个辅助头时	中到高

具体改进	原理	主要优点	主要缺点/风险	实现要点	参考实现/证据	适用场景	预期收益
GRU 短时序头	用门控递归聚合 3-8 帧历史信息	简单、稳、推理成本低，适合先做时序化	长时依赖有限，极端遮挡恢复能力一般	放在多尺度融合之后，比直接对原图序列做 RNN 更稳	LN 对 RNN 稳定有效；大量驾驶系统先用轻量递归作过渡 ⁸	先解决转弯抖动、跟车平滑、短遮挡	中到高
CfC/LTC/NCP 时序头	连续时间递归模型，显式建模不规则时间和动态过程	在时序建模上比普通 RNN 更贴近控制问题，CfC 速度/效率优势明显；NCP 还带一定可审计性	工程生态不如 GRU 普及；调参经验少于 Transformer	先在轨迹 head 或控制 head 前替换 GRU；保留 CNN 主干不动	CfC 论文报告较 ODE 类模型快 1-5 个数量级；官方 ncps 库可直接接入 PyTorch/TensorFlow ⁹	帧率波动、控制连续性要求高、想做可解释递归	中到高
Streaming Transformer	用时空 self-attention 或 memory token 建模更长依赖	对交叉口、遮挡、低可见和多主体交互更强	训练和推理都贵，延迟与显存压力大	不建议一上来就 full attention；优先局部窗口 + memory token + register token 压缩	BEVFormer 时空 transformer；DrivOR 用 camera-aware register 压缩计算；CarLLaVA 也走时序视觉 token 路线 ¹⁰	中长期升级，交叉口/复杂交互多	高
多尺度特征融合	FPN/BiFPN/分层 token，让近距离可控区域和远距离结构线索同时可见	对道路类型变化、城市场景纹理差异更稳	需要仔细做 head 对齐，否则收益不稳定	用轻量 BiFPN 或双向特征聚合，比只取单层主干特征明显更稳	BEVFormer、PersFormer、CalibFormer 都强调多层特征聚合的重要性 ¹¹	高速+城区混合、视距波动大	高
SE/CBAM 等轻量注意力	对通道或空间做重标定	接入成本极低，常能稳定增加少量鲁棒性	上限有限，不能代替时序和几何建模	推荐加在 backbone 后半段或 neck，而不是全网乱加	SE、CBAM 都是轻量通用模块，几乎零门槛 ¹²	低风险小步快跑	低到中

具体改进	原理	主要优点	主要缺点/风险	实现要点	参考实现/证据	适用场景	预期收益
光流/运动流融合	从 RGB 差分或光流中提取运动线索，再与静态视觉特征融合	对动态主体、相对速度、夜晚边缘模糊特别有价值	额外算力或预处理链路；流估计误差会传递	若算力一般，可先用差分帧或轻量 flow token；若算力充足可接 SEA-RAFT	Optical Flow Matters 在单目 steering 上报告误差下降 31%；SEA-RAFT 提供更高泛化和效率的光流实现 ¹³	夜间、雨天、跟车、切入切出频繁	中到高
深度辅助分支	单目自监督/弱监督深度作为辅助任务，帮助网络建立尺度与可通行空间	对相机参数变化、坡道、压缩视角更有帮助	深度估计不准时会引入伪几何	不建议把深度当硬约束；建议作为 auxiliary feature 或 distillation target	MGNet 把自监督深度与 panoptic 结合；早期多任务深度/语义加权也有成熟证据 ¹⁴	坡道、乡村道路、相机参数变化	高
语义/实例/道路结构辅助分支	用语义分割、实例、lane segment、road graph 强化结构理解	对道路边界、车道、路口规则等泛化更强	标注头过多会拖慢训练；实例头较重	优先“语义 + 车道”而不是一上来做 full panoptic	LaneSegNet、OpenLane-V2 强调 geometry + topology；EMMA road graph 共训有效 ¹⁵	规则密集城市、复杂路口	高
几何条件适配器	把相机内参、裁剪、安装位姿、FOV 编码成 token/FiLM/adapter，参与特征调制	直击跨相机参数泛化问题	若训练域内相机变化太小，收益要靠专门协议才能显现	推荐注入到 neck 之前和轨迹 head 之前各一次	PersFormer 相机参数参考变换；STMono3D 指出跨域几何失配会造成 depth shift ⁵	多车型、多相机、不同裁剪策略	高
概率规划/不确定性头	输出轨迹分布、风险图或 aleatoric uncertainty，而非唯一确定动作	对多模态驾驶行为和低可见场景更稳，能抑制过度自信	训练更复杂；评价指标要跟着升级	轨迹 K 模式 + confidence、或 BEV drivability uncertainty 均可	VADv2 概率规划；SUPER-AD 把语义不确定性直接注入规划；DiffE2E 用扩散+监督混合解码器 ¹⁶	夜雨雾、长尾、交互不确定性大	很高

具体改进	原理	主要优点	主要缺点/风险	实现要点	参考实现/证据	适用场景	预期收益
轨迹—控制 双分支	同时预测轨迹和低级控制，再做融合或控制器解码	比直接控制更稳，比纯轨迹更灵活；TCP 的经验非常强	分支协调不好会互相干扰	推荐主输出统一到 trajectory，再由轻量控制 head 细化纵横向	TCP 官方基线就是此思路，并在单相机 CARLA 上很强 ¹⁷	几乎所有单目端到端系统	很高
解释头/语言说明头	输出子分数、显著区域、文字评论或决策理由	便于审计和错误定位，对工程迭代非常有价值	直接提升闭环分数的幅度通常不大，推理开销可能增加	更推荐“子分数/注释头”而不是完整大语言模型接管主控制	CarLLaVA 可输出语言 commentary；DriveGPT4 强调可解释问答与控制；NCP/CfC 也提供较好可审计时序结构 ¹⁸	安全审计、故障复盘、人机共驾	中
GN/LN 替代 BN	让归一化不依赖 batch 统计	对小 batch、视频训练、跨域稳定性更好	个别 CNN 结构要重新调学习率	Conv 主干优先 GN，Transformer/时序模块优先 LN	GN 在小 batch 下显著优于 BN；LN 对 RNN/序列稳定有效 ¹⁹	显存受限、视频/多头训练	中到高
蒸馏 + 量化友好头	先用大模型教小模型，再做 QAT/PTQ	部署收益直接，且常能减少 domain shift 下的过拟合波动	流程复杂；不当 PTQ 会损伤敏感 head	优先蒸馏中间特征和轨迹分布；最终部署优先 QAT 而不是只做 PTQ	Hinton 蒸馏；TensorRT 文档说明 PTQ/QAT 差异与 calibration 要求 ²⁰	嵌入式落地、延迟严格	中

上表中，最值得你优先关注的不是某一个“孤立模块”，而是三组组合拳。第一组是“**多尺度 + 几何条件 + 深度/语义辅助**”，它解决的是网络是否真正在理解道路结构，而不是死记纹理风格；第二组是“**GRU/CfC 或 streaming transformer + 轨迹—控制双分支**”，它解决的是网络是否具备时间连续性与控制平滑性；第三组是“**概率规划/不确定性头 + 解释头**”，它解决的是网络在 OOD 场景下是否会‘不知道自己不知道’。这三组能力分别对应表征鲁棒、决策鲁棒和审计鲁棒。 ²¹

对比矩阵与相对收益判断


下表是一个更适合做工程决策的“决策矩阵”。它不是统一 benchmark 下的精确实测，而是依据上述论文和开源实现，对**实现复杂度、训练成本、推理成本、跨场景增益预期、可调试性、是否需要额外标注/数据**做的综合评级。

改进项	实现复杂度	训练成本	推理成本	跨场景增益预期	易于调试	是否需额外标注/数据
多任务辅助头	中	中到高	低到中	高	中	视任务而定
动态任务加权	中	中	低	中到高	中	否
GRU 时序头	低到中	低到中	低	中到高	高	否
CfC/LTC/NCP 时序头	中	中	低到中	中到高	中	否
Streaming Transformer	高	高	高	高	低到中	否
多尺度特征融合	低到中	中	低到中	高	高	否
SE/CBAM	低	低	低	低到中	高	否
光流/运动流融合	中到高	中到高	中到高	中到高	中	否
深度辅助分支	中	中到高	低	高	中	可用自监督
语义/实例/道路结构辅助	中到高	高	低到中	高	中	常需标注
几何条件适配器	低到中	低	低	高	高	需要相机参数
概率规划/不确定性头	中到高	中到高	中	很高	中	否
轨迹—控制双分支	中	中	低到中	很高	高	否
解释头/语言说明头	中到高	高	中到高	中	高	解释数据更佳
GN/LN 替代 BN	低	低	低	中	高	否
蒸馏 + 量化友好头	中	中到高	很低	中	中	需要 teacher 或校准数据

如果只看“跨场景增益 / 工程代价”的比值，我会把**轨迹—控制双分支、多尺度融合、几何条件适配器、GRU/CfC 时序头、深度/语义辅助头、不确定性规划头**放在第一梯队；把**SE/CBAM**放在“可以顺手加，但别寄希望于它单独解决泛化”的第二梯队；把**完整 streaming transformer、语言解释大头、扩散式解码器**放到资源更充足时再做。这个判断与 TCP、VADv2、RoCA、SUPER-AD、CarLLaVA、Optical Flow Matters 的趋势是一致的：真正显著影响 OOD 鲁棒性的，往往是时间、几何、结构先验与不确定性，而不是局部注意力模块本身。

22

为了更直观看到“相对收益”，下面给出一个**文献综合下的定性评分图**。纵轴不是统一 benchmark 的绝对分数，而是我根据公开论文中对泛化、闭环稳定性、部署可行性的综合表现，给出的相对跨域增益评分。



这个图最重要的结论只有一句：**如果你当前模型还是“单帧 backbone + MLP 控制头”，最先做的不是往上堆更多注意力，而是先把几何、时序、辅助结构先验和不确定性补齐。**这是跨场景鲁棒性提升的主干路线。 ²³

评估、基准与部署注意事项

对于只做网络侧优化的项目，我建议你至少采用“三层评估”：第一层是**闭环模拟**，用 CARLA Leaderboard 或 Bench2Drive 看真实驾驶能力；第二层是**开放但更接近真实数据的 pseudo/open-loop 评估**，用 NAVSIM；第三层是**结构辅助任务评估**，用 BDD100K、OpenLane、OpenLane-V2 检查辅助头有没有真正学到道路结构。CARLA Leaderboard 覆盖 freeway、urban、residential、rural，并显式包含 daylight、sunset、rain、fog、night 等天气；Bench2Drive 把评估扩成 44 类交互场景、23 种天气、12 个 town、220 条路线；NAVSIM 则主打“更接近真实分布，同时比闭环仿真更可扩展”，其 README 明确指出 pseudo-simulation 与闭环仿真具有较强相关性，而且计算代价更低。 ²⁴

如果你要专门验证“跨光照、天气、道路类型、城市/乡村、相机差异”，BDD100K 和 OpenLane/OpenLane-V2 很适合做**结构先验与泛化诊断**。BDD100K 提供 100K 驾驶视频和 10 个任务，原始论文明确强调它具有 geographic、environmental、weather diversity；OpenLane 强调真实 3D lane 场景多样性；OpenLane-V2 则把 topology reasoning 引入结构理解，这非常适合验证你加的 lane/road graph 辅助头是否真的改善了主任务表征，而不是只提升了局部分割精度。若你未来想对接更强的真实长尾端到端评估，Waymo WOD-E2E 是值得关注的新基准，它专门从稀有场景中抽样，并引入 Rater Feedback Score 评价轨迹偏好。 ²⁵

评价指标上，不建议只看 ADE/FDE 这类几何误差。近期工作已经持续指出，传统 open-loop 轨迹误差与真实闭环 driving score 的相关性并不稳定；NAVSIM 和相关后续分析之所以有价值，是因为它们把 progress、collision、time-to-collision、comfort 等更贴近驾驶行为的指标引进来了。你自己的实验里至少应保留三类指标：一类是**闭环安全指标**，如碰撞、闯灯、路线完成率、infraction；一类是**行为质量指标**，如 progress、平均 jerk、控制平滑性；一类是**OOD 稳定性指标**，如夜间子集、雨雾子集、跨 town 或跨 city hold-out 的相对衰减率。 ²⁶

部署层面，我最强烈的建议是：**不要把 BN 当成默认选项**。单目端到端驾驶的训练常常受限于高分辨率、时序输入、多头任务和显存，因此 batch 往往不大。GN 对 batch size 不敏感，在小 batch 下显著优于 BN；LN 对递归或 transformer 序列也更稳定。因此，CNN 主干倾向 GN，时序和 transformer 子模块倾向 LN，会比“全网 BN”更稳健。 ¹⁹

压缩和推理链路上，建议采用“**先蒸馏，后量化**”而不是反过来。蒸馏可把大模型的轨迹分布、风险分数和中间结构特征迁移到小模型；TensorRT 官方文档明确指出，PTQ 需要 representative calibration data，但对复杂模型或敏感层可能导致精度下降，而 QAT 往往有更好的精度恢复。对驾驶网络特别要小心的是：分类辅助头通常很抗量化，但最终轨迹回归、uncertainty head 和细粒度几何头往往更敏感。因此更合理的实践是：主干与共享 neck 做 INT8/QAT，最终轨迹 head 可保留 FP16。 ²⁰

最后，部署鲁棒性不能只看图像腐蚀。Bench2Drive-Robust 的核心价值正在于它把**相机流丢帧、ego-state 估计误差、控制延迟**纳入闭环评测。对工程来说，这意味着你的网络除了要抗天气和光照，还要抗“设备真实世界的坏脾气”。因此，我建议你网络设计里至少保留两件事：一个是**短时序记忆**，避免单帧丢失直接导致控制跳变；另一个是**不确定性或子分数头**，让系统能在输入质量下降时显式降置信，而不是继续过度自信地输出控制。 ²⁷

优先级与实验计划

下面给出我认为最可执行的优先级路线。为了控制你项目的试验成本，我把改动分成“短期可试”“需中期资源”“长期研究”三层，每项都给出建议的数据、基线、指标、消融项和建议阈值。这里的阈值是**项目目标值**，不是文献保证值。

优先级	改进项	建议数据	建议基线	主要指标	关键消融	建议阈值
短期可试	多尺度 neck + GN/LN 替代 BN	现有主训练集 + CARLA Leaderboard 验证	你的当前单目 baseline	Driving Score、Infraction、平均 jerk	单尺度 vs 多尺度；BN vs GN/LN	闭环 DS 提升 $\geq 3\%$ ，Jerk 降低 $\geq 5\%$
短期可试	轨迹—控制双分支	CARLA / 现有闭环集	直接控制头 baseline	Route Completion、碰撞率、控制抖动	纯控制、纯轨迹、双分支	DS 提升 $\geq 5\%$ ，横向振荡显著下降
短期可试	GRU 或 CfC 短时序头	3–8 帧短序列；CARLA + 真实日志	单帧模型	DS、平均 jerk、遮挡恢复	单帧、GRU、CfC	夜间/雨天子集 DS 提升 $\geq 4\%$
短期可试	深度/语义辅助头	BDD100K、OpenLane、现有标注	同 backbone 单任务模型	闭环 DS + 辅助头 mIoU/车道指标	无辅助、仅语义、仅深度、两者同时	跨场景衰减率下降 $\geq 10\%$

优先级	改进项	建议数据	建议基线	主要指标	关键消融	建议阈值
中期资源	几何条件适配器	多相机参数版本或多车型记录	不带相机参数的序列模型	跨相机参数 hold-out DS	不输入 camera token vs 输入	跨相机 DS 提升 $\geq 5\%$
中期资源	光流/运动流融合	夜晚/雨天/高速跟车子集	RGB-only 时序模型	纵向控制稳定性、碰撞率	RGB、差分帧、SEA-RAFT flow	特定恶劣子集碰撞率下降 $\geq 8\%$
中期资源	概率规划/不确定性头	CARLA + NAVSIM	双分支 deterministic 轨迹模型	DS、NAVSIM PDM/EPDMS、risk calibration	单模态回归 vs K 模式/分布头	NAVSIM 分数提升 $\geq 3\%$ ，高风险场景误报下降
中期资源	动态任务加权	你已经加了多个辅助头之后	固定权重多任务模型	主任务 DS、辅助头稳定性	固定权重、Uncertainty、GradNorm、CAGrad	手调权重次数减少一半以上，主任务不回退
长期研究	Streaming Transformer memory	Bench2Drive / NAVSIM / WOD-E2E	GRU/CfC 强基线	闭环 DS、长路口成功率、复杂交互	GRU、局部 transformer、memory transformer	复杂交互子集提升 $\geq 5\%$
长期研究	语言解释头或子分数解释头	BDD-X / CARLA 注释数据	不解释的强规划模型	闭环 DS、解释一致性、复盘效率	无解释、子分数、多模态注释	在不损失 DS 的前提下提高可审计性
长期研究	扩散/混合动作解码器	NAVSIM / CARLA	概率规划头	多模态行为覆盖、闭环 DS	回归、混合高斯、扩散	长尾复杂场景成功率显著提升
长期研究	蒸馏 + QAT + INT8/FP16 混合部署	与训练集同分布校准集	未压缩最优模型	latency、功耗、DS 保留率	PTQ、QAT、蒸馏后 QAT	延迟下降 $\geq 30\%$ ，DS 保留 $\geq 97\%$

如果你只允许我给一个**最稳妥的六周迭代顺序**，我会这样排：第一周做 GN/LN 和多尺度 neck；第二周把单帧改成 4–6 帧 GRU；第三周加轨迹—控制双分支；第四周加语义/深度辅助并接不确定性权重；第五周在困难子集加入 light flow 或差分帧；第六周再做 uncertainty head 与量化前检查。这种顺序的好处是，每一步都可以在前一步基础上做局部增量验证，不会让你陷入“大改完不知道谁贡献了效果”的状态。其逻辑本身也与 TCP、Openpilot-Deepdrive、MGNet、Optical Flow Matters、SUPER-AD 的经验吻合：先让表征稳定，再让时序稳定，再让决策更稳健。

关键论文与开源实现

如果你只能先读五篇近五年的核心论文，我推荐按下面顺序阅读。

推荐论文	为什么值得优先读	你能直接学到什么
TCP, NeurIPS 2022	单目、闭环、结构非常务实，且官方代码可复现	为什么“轨迹—控制双分支”比纯控制更稳；如何做端到端强基线 ¹⁷
VADv2, 2024	把 camera-only 规划推向概率建模，代表了从 deterministic 到 probabilistic 的关键转向	为什么多模态行为要建成分布；如何减少笼统 waypoint 回归带来的不确定性损失 ²⁹
CarLLaVA, 2024	camera-only 闭环、还带语言 commentary，是可解释端到端驾驶的重要样板	如何在不完全依赖额外昂贵标签的情况下实现解释性输出 ³⁰
RoCA, 2025	直接聚焦跨域泛化与适配，是你“跨场景鲁棒性”问题最对题的论文之一	如何把“跨城市/跨域”当成模型结构问题，而不是只当成数据问题 ³¹
SUPER-AD 或 DiffE2E, 2025	一个强调不确定性规划，一个强调扩散式混合动作解码，都是当前前沿方向	SUPER-AD 适合研究安全与置信，DiffE2E 适合研究多模态行为建模 ³²

如果你只能先落地两个开源资源，我建议直接用下面两个。

第一，**OpenDriveLab/TCP**。它是目前最像“单目端到端鲁棒性工程起点”的官方仓库之一，README 明确给出训练、评估、CARLA 数据生成与脚本，且论文/仓库都强调其在单相机 CARLA Leaderboard 上的强表现。对你来说，它最有价值的不是“拿来即用”，而是它把很多有效结构都压缩成了一个相对可控的系统。

第二，**autonomousvision/navsim**。如果你的重心是跨场景稳健性，而不是只在固定 CARLA 路线上刷分，那么 NAVSIM 更像现代评测中枢。它的官方仓库把 pseudo-simulation、PDM/EPDMS、标准化 split 和挑战赛流程都开放出来，而且明确强调与高成本闭环评测存在较强相关性。对于网络优化项目来说，它非常适合做“中期回归测试平台”。

综合下来，我的最终建议可以压缩成一句话：**先把你的单目网络做成“几何感知的多尺度时序规划器”，再谈更大的 backbone、更复杂的解释模型和更重的生成式解码器**。这是今天在公开研究与高质量开源中，最可执行、也最符合跨场景鲁棒性目标的网络侧路线。

¹ ¹⁷ ²² Trajectory-guided Control Prediction for End-to-end Autonomous Driving: A Simple yet Strong Baseline

https://arxiv.org/abs/2206.08129?utm_source=chatgpt.com

² ¹⁹ Group Normalization

https://arxiv.org/abs/1803.08494?utm_source=chatgpt.com

- 3 24 26 **CARLA Autonomous Driving Leaderboard**
<https://leaderboard.carla.org/>
- 4 5 23 35 **PersFormer: 3D Lane Detection via Perspective Transformer and the OpenLane Benchmark**
https://arxiv.org/abs/2203.11089?utm_source=chatgpt.com
- 6 **EMMA: End-to-End Multimodal Model for Autonomous Driving**
https://arxiv.org/abs/2410.23262?utm_source=chatgpt.com
- 7 **Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics**
https://arxiv.org/abs/1705.07115?utm_source=chatgpt.com
- 8 **Layer Normalization**
https://arxiv.org/abs/1607.06450?utm_source=chatgpt.com
- 9 **Closed-form Continuous-time Neural Models**
https://arxiv.org/abs/2106.13898?utm_source=chatgpt.com
- 10 11 **BEVFormer: Learning Bird's-Eye-View Representation from Multi-Camera Images via Spatiotemporal Transformers**
https://arxiv.org/abs/2203.17270?utm_source=chatgpt.com
- 12 **Squeeze-and-Excitation Networks**
https://arxiv.org/abs/1709.01507?utm_source=chatgpt.com
- 13 **Optical Flow Matters: an Empirical Comparative Study on Fusing Monocular Extracted Modalities for Better Steering**
https://arxiv.org/abs/2409.12716?utm_source=chatgpt.com
- 14 21 **MGNet: Monocular Geometric Scene Understanding for Autonomous Driving**
https://arxiv.org/abs/2206.13199?utm_source=chatgpt.com
- 15 **LaneSegNet: Map Learning with Lane Segment Perception for Autonomous Driving**
https://arxiv.org/abs/2312.16108?utm_source=chatgpt.com
- 16 29 **VADv2: End-to-End Vectorized Autonomous Driving via Probabilistic Planning**
https://arxiv.org/abs/2402.13243?utm_source=chatgpt.com
- 18 30 **CarLLaVA: Vision language models for camera-only closed-loop driving**
https://arxiv.org/abs/2406.10165?utm_source=chatgpt.com
- 20 **Distilling the Knowledge in a Neural Network**
https://arxiv.org/abs/1503.02531?utm_source=chatgpt.com
- 25 **BDD100K: A Diverse Driving Dataset for Heterogeneous Multitask Learning**
https://arxiv.org/abs/1805.04687?utm_source=chatgpt.com
- 27 **Bench2Drive-Robust: Benchmarking Closed-Loop Autonomous Driving under Deployment Perturbations**
https://arxiv.org/abs/2605.18059?utm_source=chatgpt.com
- 28 33 **GitHub - OpenDriveLab/TCP: [NeurIPS 2022] Trajectory-guided Control Prediction for End-to-end Autonomous Driving: A Simple yet Strong Baseline. • GitHub**
<https://github.com/OpenDriveLab/TCP>
- 31 **RoCA: Robust Cross-Domain End-to-End Autonomous Driving**
https://arxiv.org/abs/2506.10145?utm_source=chatgpt.com

32 SUPER-AD: Semantic Uncertainty-aware Planning for End-to-End Robust Autonomous Driving

https://arxiv.org/abs/2511.22865?utm_source=chatgpt.com

34 NAVSIM: Data-Driven Non-Reactive Autonomous Vehicle Simulation and Benchmarking

https://arxiv.org/abs/2406.15349?utm_source=chatgpt.com